论文编码：RUC-BK(FX)-080901-2019200887

中国人民大学本科毕业论文（设计）

中文文本情感分析词典的自适应改进

——以东方财富网上证指数吧评论数据为例

作　　者：李化冰
学　　院：高瓴人工智能学院高礼研究院
专　　业：计算机科学与技术
年　　级：2019 级
学　　号：2019200887
指导教师：谢红

论文成绩：A-

完成日期：2023 年 05 月 18 日

中国人民大学学位论文原创性声明和使用授权说明

原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

论文作者签名：李化冰

日期：2023 年 05 月 18 日

学位论文使用授权说明

本人完全了解中国人民大学关于收集、保存、使用学位论文的规定，即：

- 按照学校要求提交学位论文的印刷本和电子版本；
- 学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

论文作者签名：李化冰

指导教师签名：谢红

日期：2023 年 05 月 18 日

摘要

伴随着计算机科学大数据技术对传统社会科学学术研究范式的不断重构，非结构化的文本数据日益成为诸多领域实证研究的重要依托。传统社会科学实证研究多以宏观统计、问卷调查、公司财报、股市价格等结构化数据为基础，计算机科学与技术自然语言处理中文本情感分析方法的出现，极大拓展了社会科学实证研究的数据来源和研究领域，深刻改变和重塑了社会科学实证研究的面貌。当前，文本情感分析方法大致包括基于词典的方法、基于机器学习的方法和基于深度学习的方法。其中，基于词典的方法由于计算简单、易于理解、可信性强、成本较低，多为社会科学研究人员所采用。但是，由于中文文本情感分析的成熟词典目前仍然较少，且缺少高度专门化的领域词典，文本情感分析的准确程度仍有进一步提高空间。

如何在不引入人工标注训练数据的基础上，进一步提高文本情感分析的准确性？本文以东方财富网上证指数吧的评论数据为例，阐述了一种中文文本情感分析词典的自适应改进方法：首先，在进行全部文本分词同情感词典对照打分之前，先利用基础通用词典进行一次小批量打分。为避免单一的词典法对文本理解造成偏误，利用机器学习方法对已经获得的打分数据进行有监督学习，从而扩充小批量样本。继而，通过构建 TF-IDF 矩阵并去掉重复词汇，可以进一步提取于文本中具有重要意义、但未被基础通用词典正确识别情感的词语，并将其添加到通用词典中，以形成对词典的自适应改进。最后，利用补充后的自动拓展词典进行完整打分，获得全部数据的文本情感分析结果。

继而，本文将自适应改进后得到的文本情感分析结果、基础词典测算结果和基于各种机器学习方法的结果一并，利用人工标注的数据进行了检验。检验结果表明，自适应改进后的文本情感分析相较基础词典的结果有所改进，且优于部分机器学习方法。考虑到计算、理解、信度和成本等多方面因素，这种改进是有益的。综上，本文提出的中文文本情感分析词典的自适应改进方法，将对社会科学研究中颇为常用的中文文本情感分析，尤其是高度专门化、预算强约束、高稳健性要求的文本情感分析，具有一定的启发与价值。

关键词：文本情感分析　自适应改进　“股吧”评论　情感词典　机器学习

Abstract

Along with the continuous reconstruction of the traditional social science academic research paradigm by big data technology, unstructured textual data has increasingly become an important reliance for empirical research in many fields. While traditional empirical research in social sciences is mostly based on structured data such as macro statistics, questionnaires, company financial reports and stock market prices, the emergence of text sentiment analysis methods in NLP and CS has greatly expanded the data sources and research fields of empirical research in social sciences, and profoundly changed and reshaped the face of empirical research in social sciences. Currently, text sentiment analysis methods broadly include dictionary-based methods, machine-learning-based methods and deep-learning-based methods. Among them, dictionary -based methods are mostly adopted by social science researchers due to their simple computation, easy understanding, high reliability and low cost. However, as there are still few mature dictionaries for Chinese text sentiment analysis and a lack of highly specialized domain dictionaries, there is still room for further improvement in the accuracy of text sentiment analysis.

How to further improve the accuracy of text sentiment analysis without introducing artificially labeled training data? In this paper, an adaptive improvement method of Chinese text sentiment analysis dictionary is described, taking the “Guba” of Shanghai Composite Index on the East Money Website as an example: First, a small batch of scoring is performed using a basic general dictionary before scoring all text subscripts against the sentiment dictionary. In order to avoid bias in text understanding by a single dictionary method, a machine learning method is used to expand the small batch of samples by supervised learning of the scored data already obtained. Following that, by constructing a TF-IDF matrix and removing duplicate words, words that are significant in the text but are not correctly identified by the basic universal dictionary can be further extracted and added to the general dictionary to form an adaptive improvement of the dictionary. Then, a complete scoring is performed using the supplemented automatically expanded dictionary to obtain text sentiment analysis results for the entire data.

Then, the results of the basic dictionary measurement and the results based on various machine learning methods are tested together with the artificially labeled data, showing that the adaptively improved text sentiment analysis improves compared to the results of the basic dictionary and outperforms some of the machine learning methods. This improvement is beneficial considering various factors such as computation, comprehension, reliability and cost. In summary, the adaptive improvement method of Chinese text sentiment analysis dictionary proposed in this paper will be inspiring and valuable for Chinese text sentiment analysis, which is quite commonly used in social science research, especially for text sentiment analysis with high specialization, strong budget constraints and high robustness requirements.

Key Words: Text Sentiment Analysis Adaptive Improvement "Guba" Comments Emotion Dictionary Machine Learning

内容目录

1 引言.....1
2 文献综述.....4
2.1 文本情感分析的基本方法回顾.....4
2.2 文本情感分析词典的研究现状.....6
2.3 社会科学中的文本情感分析应用.....7
3 基于通用词典的股吧评论文本情感分析.....9
3.1 数据来源与数据获取.....9
3.2 数据描述与词云分析.....9
3.3 多方法下的文本情感分析.....10
4 股吧评论文本情感分析词典的自适应改进.....13
4.1 理论分析与方法设计.....13
4.2 小批量计算与机器学习样本扩增.....13
4.3 TF-IDF 计算与词典扩充.....14
5 结论.....17
参考文献.....18
致谢.....21

1 引言

实证研究（Empirical Study）和规范研究（Normative Study），一直以来都是社会科学学术研究的重要范式。其中，前者强调从经验到结论的知识生成过程，而后者则多指由逻辑演绎到理论成果的研究展开方法。伴随着计算机科学与技术的发展，数据的生成、计算与储存越发容易和普遍，实证研究的土壤和资源愈发丰富，不仅形成了一大批优秀学术成果，而且深刻改变了社会科学学术研究的面貌。进入大数据时代以来，数据的含义、种类、形式和规模前所未有地丰富、膨胀和发展起来，数据从一种简单的处理对象逐渐转化为一种基础性要素和资源。[1]由此，基于广义数据的社会科学实证研究生机蔚然，不断发挥着激发创新活力、提供发展动能、追求实在真理的重要功用。

一般地来讲，大多数社会科学实证研究的核心任务，无非“分类”（或称“聚类”）和“回归”（或称“拟合”）两种，在以描述和呈现为主要目的的实证研究中，“分类”往往比“回归”使用更多，而在追求相关性乃至因果性的实证研究中，“回归”往往比“分类”分量更重。但是无论如何，在传统的实证研究者眼中，“分类”和“回归”所需要的数据，应该是纯粹的“数”，如宏观统计、问卷调查、公司财报、股市价格等等，大段文本语句经过计算转化为情感打分进而参与到实证研究中，是之前相当长一段时间内实证研究者所无法想象的。这种由“数”到“数据”的转变，不仅深刻反映了学者对“数据”认识的不断深入，也恰恰是社会科学实证研究日益蓬勃的一个原因。

文本情感分析，也称文本情感倾向分析或文本意见挖掘，长期以来都是计算机科学与技术自然语言处理研究中的一个重要内容，现已被广泛应用于社交媒体、在线评论、商业投资等领域。总的来说，文本情感分析在方法上可分为基于词典的分析方法、基于机器学习的分析方法和基于深度学习的分析方法三种。基于词典的分析方法的历史相对较早，是伴随着文本分词、词性判断等自然语言处理问题勃兴之际发展起来的。简单来讲，通过将大段文本进行分词，而后将其与业已总结好的情感极性词典中的积极和消极词汇进行一一对应，记录对应的得分，即可计算得到文本的情感倾向。在机器学习和深度学习技术兴起后，“人工智能”的文本情感分析方式也逐渐发展起来：通过少量“人工”打标，模型即可学习标注同文本之间的内在关联，从而“智能”地大批量计算文本情感指数。[2]因此，机器学习和深度学习的分析方法一经提出，便在文本情感分析领域占据重要地位，一般来说准确度也较词典法更高。

然而，当前利用文本情感分析方法的相当一部分社会科学实证研究，仍选择以基于词典进行文本情感计算，其原因究竟为何？一个最重要的原因是，“人工智能”固然强在“智能”，但也弱在“人工”，“人工”打标虽能形成较为准确的情感识别，但其成本毕竟相对较高。尤其是，在社会科学实证研究的视野愈发宽大、野心越发广博的当下，有待情感分析的文本体量正成倍扩大，千万字、亿字级的文本情感分析已不新鲜，如果为了保证“智能”水平不变，“人工”打标的占比就不能出现大幅下滑，但这是研究预算硬约束所不能接受的。另外，机器学习方法和深度学习方法的算力要求也相较词典法更高，尤其是深度学习大模型对 GPU 和 TPU 的需求，对部分社会科学研究者而言恐意味着困难和障碍。再者，社会科学同计算机科学与技术的鸿沟也让

机器学习和深度学习技术难以深度同社会科学常用的实证方法相融合，二者也面临着因团队手工打标、数据操纵风险大等，可解释性和可信性较词典法更弱的问题。

当然，大量实证研究者在利用词典进行文本情感分析时，也遇到了相当大的困难。一方面，由于中文文本情感分析的成熟词典目前仍然较少，选择一个优秀的、可靠的词典并非易事；另一方面，大多成熟词典考虑到应用通适性，都是基于各种语料生成的通用词典，对于专门领域问题的情感识别能力往往较差，甚至存在识别结果与正确情感方向相反的情况。[3]然而，构建适应本研究领域和研究话题的专用词典的可行性又非常低，不仅构建词典的成本和耗时可能较机器学习和深度学习的手动打标更高，而且既然是自己构建词典，便存在相当大程度的主观性，又容易陷入“先射箭后画靶”的数据操纵的质疑。在这种背景下，社会科学实证研究者又不得不想尽方法提高情感分析的准确性，弥补词典法因过于简单同机器学习方法和深度学习方法在准度和效度上的差距。

因此，面对大量愿意或无奈选用词典法开展文本情感分析研究的社会科学研究者，一味鼓吹机器学习和深度学习方法在结果上的优越性恐怕于之无益，基于计算机科学与技术，提供一种不需人工打标且纯粹基于客观计算的、训练成本和算力要求较低的、但又能对既有词典法的识别结果有所提升的文本情感方法则显得尤为重要。本文即以上述需要为出发点，以通过爬虫技术获取的东方财富网上证指数吧中的 16 余万条评论数据为例，阐述并实践了一种中文文本情感分析词典的自适应改进策略：

由于情感词典分析法的一大问题是通用词典无法适应专门研究问题，因此如何根据研究主题自动扩增词典，应当占据方法改进思考的第一顺位。一个简单的想法是：如果能在大规模计算之前，先行开展一次小规模计算，提取出某些重要词汇加入到词典中，那么后续计算必将大受裨益。因此，在进行全部文本分词同情感词典对照打分之前，本文首先利用基础词典进行了一次小批量打分，以便提取新的关键词。但是，为避免单一的词典法对文本理解造成偏误，例如忽视上下文关系和文本之间的关系等等，本文继而利用机器学习方法对已经获得的打分数据进行有监督学习，扩充了小批量样本，形成了一个更大的数据集。

在此基础上，如何提取重要词汇呢？由于短评论具有语义集中、文本直白、逻辑简单的特点，已经被识别为正向或负向情感的语句，其中大多词汇应该是同向积极或消极的。因此，本文通过构建 TF-IDF 矩阵并去掉重复词汇（包括新发现的在正负情感集中同时出现的关键词、已经被纳入既有通用词典的关键词等等），进一步提取了于文本中具有重要意义、但未被基础通用词典正确识别情感的词语，并将其添加到通用词典中，以形成对词典的自适应改进。最后，利用补充后的自动拓展词典进行完整打分，就可以获得全部数据的文本情感分析结果。在得到结果后，为了说明本文所阐述的改进方法相较普通词典法和部分机器学习方法之间的优劣，本文利用人工标注的数据对几种方法计算得到的文本情感进行检验。结果表明，自适应改进后的文本情感分析相较基础通用词典的结果有所改进，且优于部分机器学习方法。综上，本文的边际贡献主要体现在，基于计算机科学与技术领域知识，阐述并实践了一个能对计算、理解、信度和成本有较好平衡的、适用于社会科学实证研究的文本情感分析方法，可以对当下多数采用词典法开展的社会科学实证研究提供改进和启示。

本文的接续安排如下：第二章是一个集中的文献回顾章节，对文本情感分析常用的基本方

法、尤其是词典法，以及上述方法在社会科学实证研究中的经典应用进行了回顾；第三章开始是以东方财富网上证指数吧为例的实证部分，首先阐述了数据的来源、获取方式与描述性统计，并在此基础上基于通用的词典法进行了文本情感分析，指出了现有方法可能存在的不足；第四章开始即本文上述的对股吧评论文本情感分析词典的自适应改进，依次介绍了改进设计与结果，并进行了检验；第五章是一个简短的结语。具体结构如下图所示：

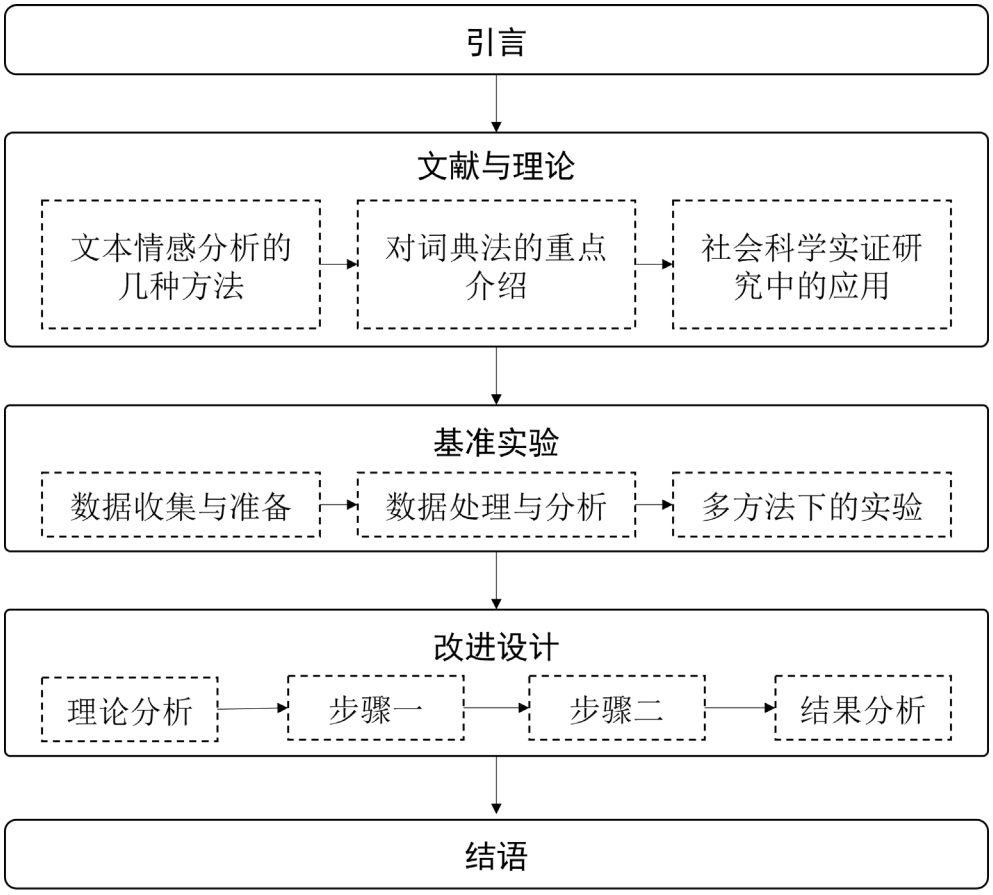

图 1　全文结构与逻辑示意图[①]

[①]图片由作者根据全文逻辑绘制。

2 文献综述

2.1 文本情感分析的基本方法回顾

正如上述，文本情感分析的三种主要方法为：基于词典的分析方法、基于机器学习的分析方法和基于深度学习的分析方法。当然，也存在如本文一样、将上述方法中的两种或多种混合并用的综合方法。对文本情感分析基本方法的回顾，有其必要性和特殊意义：一方面，后文将直接集中于以东方财富网上证指数吧评论数据为例的改进设计与结果，不再对基本方法的具体内容进行赘述；另一方面，只有回顾上述几种经典方法并将其一并对照，方能发现各种方法的优点与缺点、长处和掣肘，这也正是后文将多种方法综合起来取长补短的理论基础所在。

首先是基于词典的文本情感分析方法。基于词典的文本分析方法是上述三种方法中最早成熟应用的，也是从原理和操作上讲最简单易懂的，其核心逻辑是：首先将长段文本依靠分词算法分成词语列表，并去除掉和情感表达不相关的停用词，如果去停后的词汇同积极或消极情感词典中的词汇重合，就对应地加一分或减一分，直至所有词语遍历一次后，将得分加总，即为该文本的情感打分。上述操作中，情感词典的分类并非仅限于积极和消极两种，而可以根据需要任意构建；另外，加分减分也完全可以根据程度词进行加权，或直接对应词典中的打分。[4]词典法的优点是非常突出的：不仅由于其核心任务是匹配查找，计算成本是相当低的，普通的多核心 CPU 即可胜任；而且其工作逻辑非常简单，有利于非计算机科学与技术专业的跨领域研究人员上手学习。另外，词典法的一个核心优势是不需要人工打标，所有计算均由机器完成（虽然词典的构建在部分情况下仍需人工操作，但大多研究者的核心工作并非构建词典，已经由其他研究者贡献的词典在此部分研究者来看是“外生”的），具有相当强的可信性和可操作性。相较于人工标注下仍存在标注操纵空间的机器学习方法和深度学习方法，词典法的客观性和稳定性是高度重视研究结论可复现和稳健性的社会科学研究者所需要的。最后，正因词典法在数据标注和计算成本上的优势，其完成成本也相对较低，可以适用于部分相对独立的研究者和研究团队，不必组建或聘用数据打标团队。[5]

当然，正如上述，词典法的难点和重点在于构建词典和选用词典，而非应用词典，词典的质量和适用，直接决定了文本情感分析的质量和效度。英文情感词典的发展时间较中文情感词典更早，较为成熟的词典包括 General Inquirer、[6]Senti Word Net、[7]Opinion Lexicon[8]和 MPQA[9]等等。这些词典不仅针对英文文本中通用、常见的语素进行了充分挖掘，而且考虑了英语文本的结构，同英文分词工具相配合，可以较好解决英文文本情感分析的问题。但是，中文情感词典发展则相对较晚，且迄今为止仍少有非常成功、普遍适用的词典，相对较为优秀的词典包括 How Net 中文词典、[10]台湾大学 NTUSD 字典、[11]大连理工大学中文情感词汇本体库[12]和清华大学中文褒贬意词典，[13]等等。但是，这些词典中普遍存在的问题是：第一，词典的构造都较早，且没有保持及时更新，难以适应快速发展的中文语言环境，不少新语句、新表达的情感在这些情感词典下无法得到有效识别；第二，大多中文词典都是通用词典，不同于英语的语言结构和表达习惯，中文的变化性和多样性更强，通用词典对高度专门化的领域适用性较低，存在“水土不服”

的情况。因此，有学者针对各种具体应用领域，提出了专门化的词典，如中文金融情感词典等。[14]虽然专门化词典能对上述问题有所缓解，更好适应专门化的、新鲜化的表达，但上述问题也仍然存在，有待其他方法的加入对词典法做进一步完善。[2]

其次是基于机器学习的文本情感分析方法和基于深度学习的文本情感分析方法。本部分所述基于机器学习的文本情感分析方法，主要指基于传统机器学习的方法，即 SVM、NB、KNN 等方法，不包括深度学习方法。机器学习方法的一个普遍思路是，首先通过人工标注形成一个带有标签的数据集，具体划分为训练集和测试集，继而，通过各种方法对训练集中文本同标签之间的关系进行训练和拟合，以生成模型，并在测试集上进行测试，以不断对模型进行优化。继而，将优化好的模型应用到全部数据上，形成对全部数据的情感打分。因此，机器学习方法的核心在于以少量的“人工”形成较高水平的“智能”。[15]与之类似的，深度学习文本情感分析的基本思路同机器学习是一致的，都是通过人工打标的基础，实现“以小搏大”的过程，只是在具体方法上，深度学习所应用的多为较深的神经网络层，例如卷积神经网络、循环神经网络、LSTM 等。[16]有综述已经对基于机器学习和深度学习的文本情感分析经典研究做了回顾，形成了如下表格，对基于机器学习和深度学习方法的文本情感分析方法理解大有裨益：[2]

表 1　基于机器学习和深度学习方法的经典文本情感分析研究 ①

作者	模型	数据	准确度
谢丽星等[17]	SVM	新浪话题	67.3%
刘宝芹等[18]	NB	微博帖子	70.6%
李锐等[19]	SVM	成熟微博语料	89.4%
孙敏等[20]	BGRU	IMDB 数据集	91.2%
曾子明等[21]	BiLSTM	微博帖子	97.8%
张英等[22]	RNN	成熟微博语料	89.8%
冯兴杰等[23]	CNN	酒店评论语料	87.3%

可见，如果不考虑语料库的差异，深度学习结果在多数情况下，还是较机器学习结果更好的（当然语料库本身特征上的差异也非常重要）。一般认为，机器学习模型的结果又往往优于简单的词典法。这种准确度的层级递减与训练难度和训练成本是相对应的。但是，同机器学习相比，深度学习由于模型更深、泛化能力更强，需要耗费的算力更大，往往需要 GPU 甚至 TPU 集群完成计算，对一般社会科学研究人员而言，技术、时间和成本上的困难相对较大。另外，由于文本情感分析的数据规模越来越大，需要人工打标的数据规模也同比例放大，极大增加了训练成本，越来越多研究组不得不采取“众包”方式外派打标任务，进而造成了标注质量差、标注区别大等问题，既增加了成本，又不利于准确率提升。因此，基于自监督和自学习方法的诸多半监督学习乃至无监督学习方法也正在不断发展中，但“成本—质量”的矛盾始终是机器学习方法和深度学习方法的一个重要矛盾。由于本文重点并非机器学习和深度学习方法，加之囿于篇幅限制，对具体的机器学习和深度学习方法的大规模介绍就此略去。

总之，基于词典的情感分析方法和基于机器学习和深度学习的情感分析方法的优缺点大致

①表格基于既有文献整理得出。

如下表所述：

表 2　基于词典的方法和基于机器学习和深度学习的方法的优缺点 ①

方法	优点	缺点
基于词典的方法	计算简单、易于理解、可信性强、成本较低等	对专门化、及时化、高质量词典的要求高等
基于机器学习和深度学习的方法	准确度高、方法先进、充分发掘语义特征等	要求大数据集、成本较高、存在可信性质疑空间、“算法黑箱”、标注困难等

2.2　文本情感分析词典的研究现状

在上述回顾的基础上，聚焦基于词典法的文本情感分析前沿进展尤其重要。正如上述，词典法本身的困难不在于应用和计算，而在于情感词典的构建。一个质量高、专门化、更新快的优秀词典，将对文本分析准确率的提升起到至关重要的作用。因此，本部分将对文本情感分析中的词典问题做进一步回顾。

情感词典问题的一个重心，是情感词典的构建问题。当前，大多情感词典都是由人工方法构建起来的，这种人工构建的方式不仅对人的要求相当高，且构建成本和代价很大，因而，词典的构建没有成为嵌入社会科学实证研究中的一个环节，而是作为了一个相对独立的学术领域。[24]不仅如此，这种人工构建词典还面临着无法适应新的语料的问题，且无法适应较为专业化的研究领域。因而，采用经典词典的社会科学研究者，往往需要根据自己的研究主题向词典中添加新的内容，抑或是新词、网络词，抑或是同研究主题高度相关的专有词汇。但是，一个核心矛盾是，社会科学研究往往对研究结论有着近乎苛刻的稳健性要求，这种研究者向词典中主动添加词汇，而后再进行训练的模式，是否颇有“先射箭后画靶”的嫌疑？申言之，在研究业已完成、进入同行评议后，审稿人如何保证研究者没有刻意地通过词典的增删操纵结果？因此，一个简单的结论是：第一，情感词典的缺陷必须得到完善，这是为了提高文本情感识别准确率不得不做的一项工作；第二，情感词典的完善最好不应掺杂太多的主观因素，至少不能掺杂太多研究者自身的主观因素，从而避免数据操纵的质疑和自说自话的问题。

因而，通过客观方式（或称自然方式、自动方式）扩增情感词典，使落后、通用的词典为具体、专门的研究所用，成为一个亟待解决的问题。当前，针对情感词典的自动构建方法，已经有三种：基于知识库的方法，基于语料库的方法，以及将二者结合起来的方法。[24]基于知识库的方法是指对词与词之间的关系进行挖掘，构建通用性更强的词典的方法，包括利用同义词、近义词和反义词进行词典扩充的词关系扩展法，利用迭代关系寻找词与词相似性的迭代路径法和通过机器学习等方法进行词语释义拓展的释义扩展法，较为经典的文献如 Hu、[25]柳卫平、[26]Esuli[27]等学者的研究。基于语料库的方法包括利用文本上下文关系进行词义和情感分析的连词关系法，也包括通过词与词之间独立性来计算情感联结的词语共现法。[28]当然，将二者相结合的方法，即指上述不同方法的混合应用。当前，这些方法在中文文本分析中的应用不可谓多，原因大致有

①表格根据上文分析总结得出。

以下几点：第一，中文知识库和语料库的匮乏，是同词典的匮乏同根同源的，很难通过知识库和语料库的赋能，实现词典的完善；第二，中文本身同英文并非对照关系，而是有自己的结构与特征，方法不能简单套用；最后也是最重要的一点是，上述方法在应用上仍不可为简单清晰，对于大多数社会科学研究者而言，仍存在诸多困难。比如，在实践难度上，上述方法作为对词典法的完善，复杂程度甚至比词典法本身更高，在实现成本上，不少方法也以机器学习和深度学习方法为基础，对算力的节约是有限的。因此，中文文本情感分析词典的自动扩增问题，仍有相当大的讨论空间。

2.3 社会科学中的文本情感分析应用

最后，由于本文所涉的中文文本情感分析词典的改进问题，是针对社会科学实证研究人员的实际应用的，因而有必要对文本情感分析方法在社会科学领域的经典应用做一个非常简短的回顾。社会科学这一概念，是极其庞杂、广大的，难以也没有必要通过某些具象的定义予以框定。简而言之，一切同社会运行、社会现象和社会发展有关的学术研究，都可以成其为广义上的社会科学。其中，社会科学实证研究（类似的概念还包括计算社会科学等）正以蓬勃速度发展起来，支持计算社会科学的机构也大幅增加，这些研究往往广泛收集、分析、阐释了各种数据，产出了相当一部分有价值的成果，极大地提高了人们对社会不平等、传染病传播等重要社会现象的认知。[29]计算机科学与技术的文本情感分析方法的加入，让社会科学对海量文本的情感捕捉成为可能，社交媒体、在线评论、商业投资等领域的社会科学实证研究，已经深刻为文本情感分析所改变。

例如，在民众评论情绪研究中，较为经典的有：刘慧慧等利用 SVM 的机器学习情感分析方法，探究了新冠疫情事件中民众情绪的发展与演进，[30]类似的还有管雨翔等对突发事件网络舆情的词典构建研究；[31]曾偲慧等以某电商平台上的面膜产品为例，研究了电商产品评论情感同感知质量评价的关系；[32]马超等学者也以微博平台上政务主题的相关评论为数据源，研究了情感分析方法的应用。[33]与民众评论情绪研究类似但有所不同，针对正式文本，亦有诸多研究展开了探索。李晓霞等对“一带一路”的新闻报导文本展开了文本情感分析，[34]吴俊的等学者分析了区块链产业的新闻情感，[35]等等。甚至，对于古中文和少数民族中文，也已经有了相当数量的研究，例如单睿康等学者对藏文本情感的研究、[36]伊尔夏提·吐尔贡等学者对维吾尔文本情感的研究、[37]张卫等学者对古诗文文本情感的研究，[38]等等。本文以东方财富网上证指数吧的评论数据作为数据源，关注的问题是金融领域中文文本情感分析词典的构建。事实上，金融领域的文本情感分析实践已然颇多，例如胡家珩等学者基于深度学习方法构建了金融词典，[39]范小云等学者基于混合文本情感分析方法对股吧数据进行了测算，[40]等等。

上述研究无疑为本文的具体展开提供了宝贵借鉴，但一个不容忽视的问题是，上述研究中应用文本情感词典自动扩增技术的仍然相对较少，因而有将文本情感分析准确度在不大幅提高计算体量和开销的前提下进一步提升的空间。但是，遗憾的是，目前注意到这种准确性提升空间并在研究中有所贯彻的研究仍然相对较少，这种准确性的“量的提升”事实上有可能为最终实证结果的显著提供“质的飞跃”。因此，本文将着力于讨论适用于社会科学实证研究的中文文本情

感分析词典自动扩增方法，以期对广大对文本情感分析应用有兴趣的社会科学实证研究人员有所启示。

3 基于通用词典的股吧评论文本情感分析

3.1 数据来源与数据获取

本文选取的数据源是东方财富网的上证指数吧的股民评论数据。东方财富网由东方财富信息股份有限公司主营，是我国国内用户访问量最多、用户粘性最高的互联网股市平台，旗下“股吧”是网站的核心业务之一，每一个上市公司均有一个与之对应的“股吧”，吸引了大量股民实时交流、评论。其中，上证指数吧由于其性质特殊，吸引了最多网民参与留言，平均每分钟都有新的留言产生。之所以选择东方财富网上证指数吧的评论数据作为数据源，主要有以下几点考虑：第一，上证指数吧作为东方财富网中最为重要、最为特殊的“股吧”，吸引留言最多，讨论面向也最广，很能够代表市场的综合情绪和整体情感；第二，东方财富网对通过爬虫技术获取数据较为宽容，本文的数据获取也遵循了适当有序的基本原则；第三，东方财富网上证指数吧的评论数据很好体现了“文本短”“内容新”“领域专”等诸多特征，对基于词典法的文本情感分析非常有挑战性，也就提供了进一步改进方法的空间。

本文利用 Python 语言及各种成熟库获取东方财富网上证指数吧的评论数据。由于本文并不需要基于爬取到的数据进行接续实证研究，爬取一定量的文本集即可满足需求，故而本文将爬取范围限定在了第 1 页至第 2023 页，即约 3 个月内的全部评论数据。首先，通过 Requests 库，向网站请求网页内容，并经过 Etree 解析 HTML 语言。继而，利用 Xpath 定位需要的评论、时间、跟贴数等内容，并将数据保存下来，形成一个 DataFrame。经过上述处理，共获得评论 161840 条，2565304 字，这个数量级的文本已经足够后文利用情感词典进行文本分析。同时，本文划分了 1723 条评论作为训练集、300 条评论作为测试集，以便后文利用人工标注数据进行结果检验。

3.2 数据描述与词云分析

继而，分析爬取到的文本数据。第一步，对文本数据进行分词处理。本文选用的分词工具是 Jieba，利用其分词 Cut 功能，本文将 16 余万条评论数据分别分割为了以词为单位的字符段，并将其放置于列表中。第二步，由于并非所有词都具有文本情感分析上的意义（如“你”“我”“的”“即”“也”等等），需要利用停用词列表将上述无意义的词语去掉。本文将常用的中文停用词表、哈尔滨工业大学停用词表、百度停用词表和机器智能实验室停用词表合并起来，共同为上述已经分词后的数据进行去停。经过去除停用词后，分词列表更为干净、突出，可以为后文进一步分析提供便利。

上述数据处理后，有必要对数据的特征做一个简要的分析。首先，由于 16 余万条评论共计 256 余万字，每条评论的字数仅为 16 字左右；去除停用词后的分词列表共包括 816684 词，即每条评论中的有效词汇仅 5 词左右，这表明股吧评论数据是精练、简洁的，事实上，这也同我们的基本判断相符：由于股民往往“盯盘发帖”，即一边关注股市、一边发帖评论，少有股民会花费 5 分钟甚至 2 分钟组织语言、形成短评，大多数评论都是非常简短、直抒胸臆的。这就意味着，如果情感词典无法发掘平均每条评论 5 词的有效词汇，那么该条评论只能被认为不包括情感信

息，而这又往往与实际情况相悖，因而凸显出方法改进的必要性来。同时，为了更进一步地呈现对上述数据的感性认知，本文利用分词去停后的数据，绘制了下图词云图：

大盘
指数
涨
跌
明天
主力
内资
跑
股
股票
牛市
股市
A股
资金
注册
行情
大笑
3300
上涨
买
大跌
韭菜
高开低走
暴跌
证券
尾盘
疯狂
概率
接盘
说
哭
赚钱
满仓
买入
白酒
垃圾
震荡
走势
机会
上证指数
上午
真的
前
制
想
亏损
开盘
利好
短线
银行
清仓
交易
大涨
这是
跳
低开
周四
真
微笑
高
线
太
干
牛
下午
突破
券商
赚
补
3000
2800
加油
看空
基金
回调
新股
回落
周一
亏
诱多
3400
玩
分析
希望
绿
拉
天天
机构
结束
创业板
赶紧
人工智能
笑
美股
卖出
日
分钟
新
票
回
抄底
风险
高位
高开
吃
死
两天
赞
SH000001
旺柴
拉升
反弹
完
周五
20
个股
低
估计
下周
肯定
今日
涨停
4000
捂脸
走
北向
昨天
点
调整
亿
流出
板块
做
几天
时间
炒
补缺
日线
套
经济
钱
中
散户
上证
中国
连续
缺口
半导体
数字
转发
投资
厉害
空仓
年
跳水
碰
收盘
怒
滴汗
炒股
看好
新能源
操作
3200
盘
尾
股
证券
狗
感觉
吡
30
3310
趋势
科技
外资
资
红
破
路
业绩
做空
鼓掌
逼
冲高
卖
一点
2023
开启
杀
沪
上午
前
制
想
亏损
开盘
利好
短线
牛
太
微笑
高
线
真
周四
低开
诱多
这是
大涨
干
交易
清仓
牙
2800
加油
看空
基金
回调
新股
回落
周一
亏
3400
玩
分析
希望
绿
机构
结束
创业板
赶紧
人工智能
笑
美股
卖出
日
分钟
新
票
回
抄底
风险

表所示：

表 3　六部词典的基本情况 ①

词典	正向词汇数	负向词汇数	通用或专门	语言
How Net 词典	4566	4370	通用	中/英文
NTUSD 词典	2810	5830	通用	中文
大连理工大学词典	11235	10783	通用	中文
清华大学词典	5567	4468	通用	中文
中文金融词典（姚加权等）	3858	2080	专门	中文
中文金融词典（姜复伟等）	3338	5890	专门	中文

本文采用最为简单直接的词典打分方法：即，将每条评论分词、去停后的词语一一同词典比较，如若与正向词汇相符合，即在评分中加 1 分，如若与负向词汇相符合，则在评分中减 1 分，直至遍历所有词语，形成每条评论的情感打分。需要说明的是，由于每条文本都是短文本，每天的评论数量又非常大，因而对每条评论的情感打分做更准确的预测是意义不大的，相反，情感打分方向的正确率实则为我们所关注，即：在打分后，还需将情感打分按照同 0 的关系划分为正向和负向两个类别，各个评论的情感类别判断准确后，将每日评论得分相加，即可得到该日市场情绪的衡量。继而，由于本文划分了 1723 条评论的训练集和 300 条评论的测试集，故而可以在 300 条评论的测试集中进行测试，以进一步形成准确率数据。经过一一计算，上述六部词典对评论数据的情感打分如下表所示：

表 4　六部词典的情感分析方向准确率 ②

词典	准确率	词典	准确率
How Net 词典	67.7%	清华大学词典	69.7%
NTUSD 词典	71.3%	中文金融词典（姚加权等）	74.3%
大连理工大学词典	73.0%	中文金融词典（姜复伟等）	74.7%

在此基础上，为形成对照，本文也计算了利用几种经典机器学习方法（线性分类、朴素贝叶斯、支持向量机、KNN）得到的准确率，如下表所示：

表 5　机器学习的情感分析方向准确率 ③

方法	准确率	方法	准确率
线性分类	75.0%	支持向量机	81.3%
朴素贝叶斯	77.0%	KNN	79.7%

进而，不妨将六部词典的计算结果和四种机器学习方法的计算结果以更直观的图示展示出来：图中，橙色方点为通用词典的准确率结果，绿色方点为专用词典的准确率结果，蓝色方点为机器学习的准确率结果，圆点为各种方法的准确率重心。由图清晰可见，专用词典的识别准确率明显高于通用词典，而机器学习方法又明显高于专用词典方法。那么，自适应改进下，又能实现

①表格根据各词典实际情况总结得到。

②表格根据既有数据计算得到。

③表格根据既有数据计算得到。

何种准确率提升呢？这有待后文进一步论述。

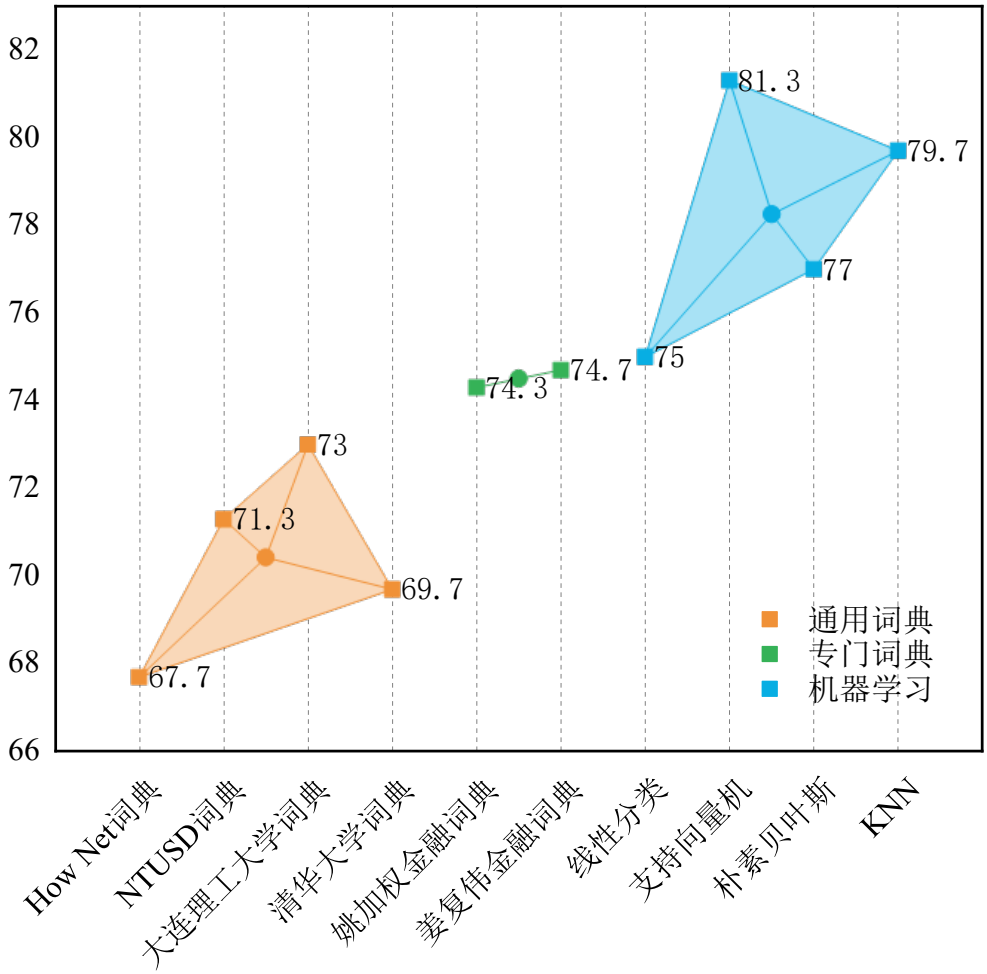

图 3　多方法下的文本分析结果可视化 ①

①由作者根据表 4、表 5 数据绘制。

4 股吧评论文本情感分析词典的自适应改进

4.1 理论分析与方法设计

上文通过传统词典方法计算了文本情感，并进行了准确率的测试。从结果来看，至少应当得出以下几个结论：第一，情感方向预测准确率最低的是利用 How Net 词典得到的结果，最高的是利用机器学习中朴素贝叶斯方法得到的结果，且机器学习方法的正确率在总体上高于词典法（在数据标注量不甚很大的前提下），说明机器学习方法（遑论深度学习方法）对词典法就准确率而言是有一定优势的；第二，六部情感词典的分析中，专门化词典的预测准确率显著高于通用词典，这说明专门化的、适用化的、内容新的词典在提高文本情绪识别准确率上具有相当大的作用，因而需要着力在完善词典上下功夫。

那么，采取什么样的方法完善上文的词典分析方法呢？正如上文所述，广大社会科学实证研究者所迫切需要的，是一种不需人工打标且纯粹基于客观计算的、训练成本和算力要求较低的、但又能对既有词典法的识别结果有所提升的文本情感方法。出于这样的需求导向，几个要点必须得到明确：第一，虽然本文对 2023 条评论数据进行了标注，但这是为上文机器学习文本情感分析计算所需要的，不能将人工评论的数据引入到改进方法设计中来；第二，新的改进方法固然会较原有方法增加一定的计算复杂度，但这种增加必须保持在一个可接受的范围内，而不能“买椟还珠”，大大增加词典法的计算压力；第三，新的方法应当相对稳健，尽量应用易于理解和解释的客观计算方法，且能够容易复现结论。

出于以上考虑，一个简单思路是：直接将全部文本数据丢给情感词典、计算情感打分的“粗放式”计算方法必须得到进一步细化，且最好能在细化的过程中不断完善词典本身，从而提高预测的准确率。为此，本文设计了一个从小批量词典文本情感计算到机器学习样本扩增，再到 TD-IDF 计算和词典扩充，最后计算全部文本情感的改进方案。

4.2 小批量计算与机器学习样本扩增

首先需要完成的是小批量计算。何谓小批量计算？即，不直接利用现有词典完成全部文本数据的计算，而是先从数据中随机抽取一个部分，先利用现有词典计算这个部分的情感打分。事实上，上述过程没有任何理解和操作上的难度，重点是为什么需要这样的一个计算过程。正如上述，“股吧”评论文本数据的特点是短小精悍、直抒胸臆，一条评论仅 10 余个字，难以表达复杂情感（例如，在 10 余个字的一句话中哪怕完成一个转折逻辑，都并非易事），这就意味着一旦某个句子包含了通用情感词典中的积极或消极词汇，那么这个句子属于积极或消极情感的概率是相当大的。而且，即便这样的逻辑不能作用于所有句子，毕竟不同个体的表达习惯和表意逻辑往往有所差别，但只要小批量计算选取得样本不太少，能够形成一个统计学意义上的“大样本”，那么从统计上就可以认为上述理论的成立。因此，小批量计算的目的是，通过通用情感词典标注一小批样本，进而将积极样本和消极样本分开来看，统计出其中未被通用情感词典识别的、但其意义和地位又非常重要的词汇，这些词汇大概率同情感词典对语句的标注是同向的。进而，将这

些词汇添加进通用词典中，就可以形成对通用词典的专门化扩增了。由于这种专门化扩增没有掺杂任何个人主观意志，且完全可以自动化计算，因此，本文将这种专门化扩增称为“自适应”的扩增，其中“自”指的是自动计算、自动总结，“适应”指的是适应文本、适应主题，从而形成了标题所述的“中文文本情感分析词典的自适应改进”。

从上文分析出发，本文随机从 16 余万条评论中随机抽取了 1000 条评论，并对这些评论利用大连理工大学词典进行了打分，由于批量的减小并不会影响情感词典法的准确度（这也正是能够利用词典法进行小批量计算的前提），因而目前的预测准确度应和上文所测基本一致，大致为 71%左右。当然，16 余万条评论抽取 1000 条评论，抽取比例似乎过低（不到 6‰），完全可以再抽取更多一些样本（例如增加到 5000 条），但为了对小批量计算过程做更精细的改进，本文提出了一个可选操作，即利用机器学习方法对上述 1000 条评论进行样本扩增。如上所述，机器学习方法的两大成本来源，一是算力需求更高（但随着计算设备的发展，已然不是最大障碍），二是人工打标需求。既然经过词典法小批量计算的 1000 条评论，目前已经有了一个粗糙的情感打分，正确率在 71%上下，就可以将其看作是有标记数据，利用这些数据进行有监督学习，利用机器学习方法再打标 4000 条评论左右，将小批量样本扩充至 5000 条数据左右。

一个随之而来的问题是，为什么要“多此一举”引入机器学习方法，而不直接利用情感词典测算 5000 条评论呢？原因在于，虽然同为情感打分，但情感词典法和机器学习法的本质逻辑是不同的，在某种意义上，前者更类似于“模仿”，后者更类似于“学习”，即：情感词典法所不能挖掘出的某些因素，是能为机器学习方法所感知到的。例如，在情感词典法下，文本的前后顺序和上下文关系是不会纳入情感分析当中的，由于“文本情感分析”和“分析文本情感”的分词结果都是“文本”“情感”“分析”，文本的结构不会影响情感得分；但是，在机器学习方法下，这种结构就可能被注意，从而影响分析结果。由于小批量计算的本质目的是发掘更多词汇而非提供更高准确度，引入机器学习方法恰能满足这一需求。为此，本文计算了上述 1000 条数据和另外随机抽取的 4000 条数据的 TD-IDF 矩阵（具体原理及操作有待后文详述），利用基于词典法的小批量标注结果，适用支持向量机方法进行了有监督学习，预测了新选择的 4000 条数据的情感极性，从而将小批量样本数量扩充至了 5000 个。

4.3 TF-IDF 计算与词典扩充

上文已经提及，在进行机器学习之前，本文对 5000 条评论数据的分词和去停结果进行了 *TD-IDF* 计算，这里有必要进一步阐述 TF-IDF 计算的具体逻辑和选择原因。TF-IDF 方法也称词频—逆文件频率方法，是发掘多篇文本之间词语重要性的一种典型算法。如其名称所示，TF-IDF 方法包括两个部分，一个是 TF 部分（即词频部分），另一个是 IDF 部分（即逆文件频率部分），TF-IDF 计算得到的结果，就是这两个部分的乘积。TF 的计算方法是：

$$\mathrm{TF} = \frac{W_{ij}}{\sum W_i} \tag{1}$$

其中 W_{ij} 代表第 i 篇文档中的词 j 出现的次数。这即是说，TF 代表某个词汇在其所在的整篇文档中的出现频率，出现频率越高，越同文本希望表达的主题相关，重要程度也就越高。但是，仅关

注 TF 是存在重大问题的，如果按照 TF 结果由高频至低频对词语进行排序，排在前列的文本大多应是非常常用但无太多意义、本应在去停阶段去除的（因为停用词词典也会存在上述词典的诸多问题），诸如“3300”“个股”“尾盘”等等。因而，为了解决这一问题，需要引入 IDF 来对这一问题进行纠正。IDF 的计算方法是：

$$\mathrm{IDF} = \log\left(\frac{I}{I_j + 1}\right) \tag{2}$$

其中 I 代表文档个数，I_j 代表包含词 j 的文档的个数。这个修正就解决了上述问题：如果一个词汇在多篇文档中总是出现，那么有理由怀疑这个词汇的性质是语言基础性的，而非专业内容性的。通过 TF-IDF 的计算，词汇在文本中的重要程度就得到了计算。

因此，将上述 5000 条数据按照积极和消极分成两类，由于 TF-IDF 矩阵已经计算得到，故而直接按照 TF-IDF 指数将词汇分别排序，即可得到积极类别和消极类别的词语重要位序。接下来，选取两类词汇中前 500 个词汇，并去除已经包括在通用情感词典中的词汇，再去除同时出现在两种类别中的词汇，即可得到需要补充到词典中，形成经自适应调整后改进的情感词典。在本文所述东方财富网上证指数吧的示例中，共保留了 217 个词汇，其中积极词汇 106 个、消极词汇 111 个。这些专门化词语的加入，将对通用情感词典形成重要改进，以进一步提高文本情感分析效果。

为验证上述改进的实际作用，本文利用上文曾使用过的 300 条验证集数据，对改进后的模型进行了检验，并将结果以准确度从高到低排序的方式呈现在了下表中：

表 6　情感分析方向准确率排序[①]

词典或机器学习方法	准确率
支持向量机	81.3%
KNN	79.7%
朴素贝叶斯	77.0%
自适应改进下的大连理工大学词典	76.7%
线性分类	75.0%
中文金融词典（姜复伟等）	74.7%
中文金融词典（姚加权等）	74.3%
大连理工大学词典	73.0%
NTUSD 词典	71.3%
清华大学词典	69.7%
How Net 词典	67.7%

另外，同上文类似，此处也将自适应改进下的大连理工大学词典计算结果绘制在图中，如下图所示。图中，紫色方点是自适应改进后的准确率结果，并以紫色横纵参考线在图中做了显著标记。可见，自适应改进后的大连理工大学词典的表现是相对突出的，相较未经改进的大连理工大学词典，准确率提高了 3.7%，不仅超越了两部金融词典的准确率（事实上两部金融词典仅为针

①表格承接上文，根据既有数据计算得到。

对金融话题，也并非针对股民评论所专用，因此也是某种意义上的“通用词典”），还超过了线性分类的准确率。虽然自适应改进的方法仍然在准确率上不及支持向量机、KNN 和朴素贝叶斯的结果，但出于计算成本、标注成本和可解释性的考虑，这个结果已然是可以接受的。

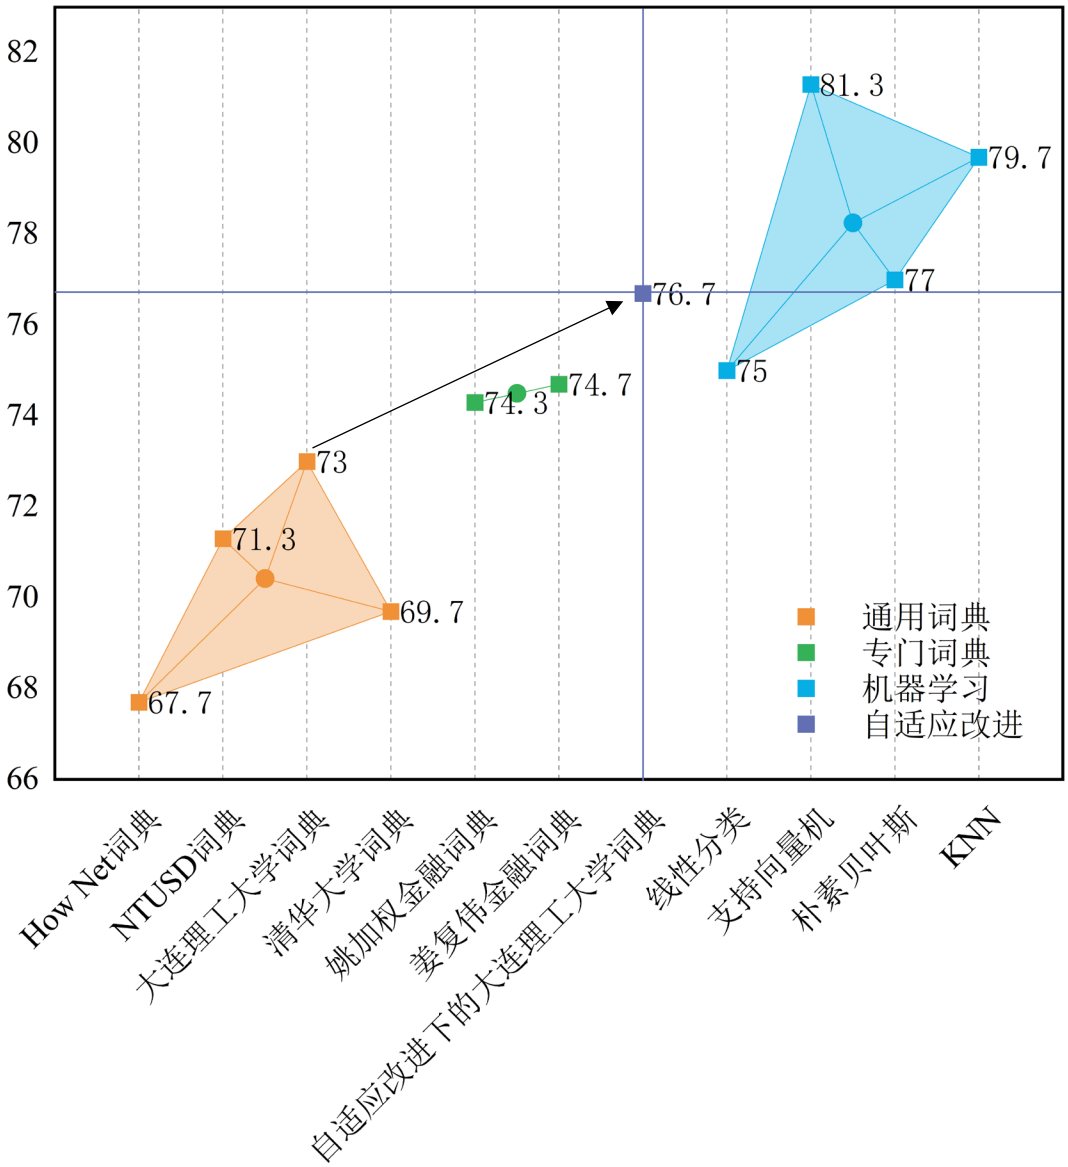

图 4　加入自适应改进方法的结果可视化

5 结论

本文阐述并实践了一种不需人工打标且纯粹基于客观计算的、训练成本和算力要求较低的、但又能对既有词典法的识别结果有所提升的文本情感方法。以东方财富网上证指数吧的评论数据为例，本文在完整词典法打分之前，先利用基础通用词典进行了一次小批量打分，目的是进一步提取文本中的特征词。为避免单一的词典法对文本理解造成偏误，本文又利用机器学习方法对已经获得的打分数据进行有监督学习，从而扩充了小批量样本。继而，通过 TF-IDF 矩阵，本文去除了高频词中同词典相重复的词汇和在积极、消极两类词典中均出现的词汇，进一步提取了于文本中具有重要意义、但未被基础通用词典正确识别情感的词语，并将其添加到通用词典中，以形成对词典的自适应改进；最后，本文利用补充后的自动拓展词典进行完整打分，获得全部数据的文本情感分析结果。结果显示，自适应改进后的情感词典打分准确率提升了 3.7%左右，不仅优于基础词典，还优于部分机器学习方法。

本文的边际贡献主要体现在，阐述并实践了一个能对计算、理解、信度和成本有较好平衡的、适用于社会科学实证研究的文本情感分析方法，可以对当下多数采用词典法开展的社会科学实证研究提供改进和启示；但也存在诸多不足：第一，本文为保持相对快速的计算速度，没有对东方财富网上证指数吧的全部评论数据进行爬取，仅爬取了 16 余万条数据，数据量在某种程度上有所不足，尤其是，由于时间窗口仅有 3 个月，尚不足支撑大多长时间窗实证研究，如后续展开实证研究，需要再行爬取更多数据，且为了证明方法的普适性，可以引入更多数据源进行实验；第二，本文所提出的改进方法仍然较为简单，没有将更复杂的情况和理论考虑在内，有进一步根据既有理论做进一步完善、提高识别新词汇的效率和准确性的空间。本文有理由相信，伴随着自适应改进的词典法文本情感分析的进一步发展，基于简单易行、可信性高、成本低廉却并不牺牲过多准确性的中文文本情感分析方法的实证研究将进一步涌现，为利用数据、理解数据、发挥数据效用提供更大贡献，实现计算机科学与技术对社会科学实证研究的赋能。

作者签名： 李化冰

参考文献

[1]孟小峰,慈祥.大数据管理:概念、技术与挑战[J].计算机研究与发展,2013,50(01):146-169.

[2]钟佳娃,刘巍,王思丽,杨恒.文本情感分析方法及应用综述[J].数据分析与知识发现,2021,5(06):1-13.

[3]范小云,王业东,王道平,郭文璇,胡煊翊.不同来源金融文本信息含量的异质性分析——基于混合式文本情绪测度方法[J].管理世界,2022,38(10):78-101.

[4]Pan D. H., Yuan J. L., Li L., et al, (2019), Deep Neural Network-Based Classification Model for Sentiment Analysis, *Proceedings of the 6th International Conference on Behavioral, Economic and Socio-Cultural Computing*.

[5]曹永红,张藜奕.基于网络爬虫的情感词典释义方式研究[J].信息系统工程.2017(12):160+162.

[6]Hartman, J. J., Stone, P. J., & Dunphy, D. C., Smith, M. S., & Ogilvia, D. M., (1967), The General Inquirer: A Computer Approach to Content Analysis. *American Sociological Review*, 32(5), 859.

[7]Stefano Baccianella, Andrea Esuli, & Fabrizio Sebastiani, (2010), Senti Word Net 3.0 : An Enhanced Lexical Resource for Sentiment Analysis and Opinion Mining, *In Proceedings of the Seventh International Conference on Language Resources and Evaluation*.

[8]Guang Qiu, Bing Liu, Jiajun Bu, Chun Chen, (2011), Opinion Word Expansion and Target Extraction through Double Propagation, *Computational Linguistics*, p.9–27.

[9]Lingjia Deng and Janyce Wiebe, (2015), MPQA 3.0: Entity/Event-Level Sentiment Corpus. *2015 Conference of the North American Chapter of the Association for Computational Linguistics – Human Language Technologies*.

[10]Qi, Fanchao and Yang, Chenghao and Li, (2019), OpenHowNet: An Open Sememe-based Lexical Knowledge Base, *Open How Net*, https://openhownet.thunlp.org/.

[11]郭顺利,张向先.面向中文图书评论的情感词典构建方法研究[J].现代图书情报技术,2016(2):67-74.

[12]徐琳宏,林鸿飞,潘宇,任惠,陈建美.情感词汇本体的构造[J].情报学报,2008,27(2):180-185.

[13]李军.中文褒贬意词典[EB/OL].http://nlp.csai.tsinghua.edu.cn/~lj/sentiment.dict.v1.0.zip,2023 年 3 月 31 日访问.

[14]姚加权,冯绪,王赞钧,纪荣嵘,张维.语调、情绪及市场影响：基于金融情绪词典[J].管理科学学报,2021.24(5),26-46.

[15]Neethu M S, Rajasree R, (2013), Sentiment Analysis in Twitter Using Machine Learning Techniques, *Proceedings of the 4th Data Analysis and Knowledge Discovery International Conference on Computing, Communications and Networking Technologies.*

[16]Yadav A, Vishwakarma D K, (2020), Sentiment Analysis Using Deep Learning Architectures: A Review. *Artificial Intelligence Review*, p.4335-4385.

[17]谢丽星,周明,孙茂松.基于层次结构的多策略中文微博情感分析和特征抽取[J].中文信息学报,2012,26(1):73-84.

[18]刘宝芹,牛耘.多层次中文微博情绪分析[J].计算机技术与发展,2015,25(11):23-26.

[19]李锐,张谦,刘嘉勇.基于加权 Word2Vec 的微博情感分析[J].通信技术,2017,50(3):502-506.

[20]孙敏,李旸,庄正飞等.基于 BGRU 和自注意力机制的情感分析[J].江汉大学学报(自然科学版),2020,48(4):80-89.

[21]曾子明,万品玉.基于双层注意力和 Bi-LSTM 的公共安全事件微博情感分析[J].情报科学,2019,37(6):23-29.

[22]张英,郑秋生.基于循环神经网络的互联网短文本情感要素抽取[J].中原工学院学报,2016,27(6):82-86.

[23]冯兴杰,张志伟,史金钏.基于卷积神经网络和注意力模型的文本情感分析[J].计算机应用研究,2018,35(5):1434-1436.

[24]Wang Ke, Xia Rui, (2016), A Survey on Automatical Construction Methods of Sentiment Lexicons. *Acta Automatica Sinica*, p.495-511.

[25]Hu M. Q., Liu B.. Mining and Summarizing Customer Reviews. *In: Proceedings of the 10th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, p.168-177.

[26]柳位平,朱艳辉,栗春亮,向华政,文志强.中文基础情感词词典构建方法研究[J].计算机应用,2009,29(10):2875-2877.

[27]Esuli A, Sebastiani F, (2007), PageRanking WordNet Synsets: An Application to Opinion Mining. *In: Proceedings of the 45th Annual Meeting of the Association for Computational Linguistics*, p.424-431.

[28]Church K W, Hanks P, (1990), Word Association Norms, Mutual Information, and Lexicography. *Computational Linguistics*, p.22-29.

[29]David M. J. Lazer et al., (2020),Computational Social Science: Obstacles and Opportunities, *Science*, p.1060-1062.

[30]刘慧慧,王爱银,刘禹彤.基于 SVM 的文本情感分析——以新冠疫情事件为例[J].信息技术与信息化.2023(01):37-40.

[31]管雨翔,王娟,刘静,秦瑞青,张鹏.突发事件网络舆情领域情感词典构建[J].情报探索.2023(02):1-8.

[32]曾偲慧,陈原,郭舒敏.基于大数据分析的电商产品感知质量评价研究——以面膜产品为例[J].中国商论.2021(08):44-49 .

[33]马超,余辉,夏文蕾,管为栋.政务微博评论中情感极性分析方法研究——以上海公安机构微博为例[J].现代情报.2020(03):157-168.

[34]李晓霞,宣长春.海外英文媒体“一带一路”新闻报道情感倾向研究[J].新闻大学.2022(06):62-74+121-122.

[35]吴俊,邵丹睿,姜尚杨帆.融合语义与情感分析的区块链产业新闻监测研究[J].现代情报.2020(11):22-33.

[36]单睿康,江涛,张婷婷,李多吉草,索南达杰.基于改进 SO-PMI 的藏文情感词典自动构建方法[J].高原科学研究.2022(01):104-112.

[37]伊尔夏提·吐尔贡,吾守尔·斯拉木,热西旦木·吐尔洪太,于清.维吾尔文情感语料库的构

建与分析[J].计算机与现代化.2017(04):67-72.

[38]张卫,王昊,邓三鸿,张宝隆.面向数字人文的古诗文本情感术语抽取与应用研究[J].中国图书馆学报.2021(04):113-131.

[39]胡家珩,岑咏华,吴承尧.基于深度学习的领域情感词典自动构建——以金融领域为例[J].数据分析与知识发现.2018(10):95-102.

[40]范小云,王业东,王道平,郭文璇,胡煊翊.不同来源金融文本信息含量的异质性分析——基于混合式文本情绪测度方法[J].管理世界,2022,38(10):78-101.

[41]姜富伟,孟令超,唐国豪.媒体文本情绪与股票回报预测[J].经济学(季刊),2021(4),1323-1344.

致谢

归期岂烂漫，别意终感激。